UNIVERSIDAD NACIONAL DE ASUNCIÓN

FACULTAD POLITÉCNICA

TEMA:

Factores asociados al acceso educativo en Paraguay y diferencias según departamento.

ASIGNATURA:

DATA-SCIENCE

GRUPO 15

INTEGRANTES:

- **Rodrigo Elias Portillo Santacruz**
- **Hugo Javier Sanchez Fidabel**

INFORME DE LA FASE 2

Desarrollo de las hipótesis, pruebas, conclusiones, etc.

Contraste 1: Años de estudio por departamento

Hipótesis nula (H_0)

- Formal: Las distribuciones de años de estudio son iguales en los 16 departamentos del país.
- Lenguaje natural: El nivel típico de años de estudio es el mismo en todos los departamentos.

Hipótesis alternativa (H_1)

- Formal*:* Al menos una de las distribuciones de años de estudio difiere de las demás.
- Lenguaje natural*:* Al menos un departamento presenta un nivel típico de años de estudio distinto al de los demás.

con un nivel de significancia de **α** = 5%

Las observaciones corresponden a personas distintas de la EPHC 2025, seleccionadas mediante un diseño muestral probabilístico, por lo que se asume independencia entre individuos de distintos departamentos.

Se verificó por medio de la prueba de Shapiro-Wilk la No normalidad de los datos de cada departamento, es visible en la tabla de arriba que Media != Mediana. Además realizando la prueba de Levene se verifica que las varianzas no son homogéneas (al menos una difiere). Ambas pruebas con un nivel de significancia α = 5%. Por lo tanto se descarta la prueba ANOVA de un factor, con post hoc de Tukey y se opta por la alternativa no paramétrica Kruskal-Wallis, con post hoc de Dunn.

Se usó el estadístico H, con 15 grados de libertad y se obtuvo el valor de $p \approx 0 < 0.05$ por tanto se rechaza Ho y se concluye que al menos una difiere.

Contraste 2: Permanencia educativa por departamentos

H_o: Oij=Eij(i,j): La asistencia al sistema educativo es independiente del departamento de residencia.

H_1: Oij != Eij para al menos un par(i,j): La asistencia al sistema educativo es dependiente del departamento de residencia.

Con nivel de significancia a=5%.

Para evaluar la relación entre el departamento de residencia y la asistencia actual al sistema educativo, se planteó la hipótesis nula H0: Oij = Eij para todo par (i,j), indicando independencia entre las variables, frente a la hipótesis alternativa H1: Oij != Eij para al menos un par (i,j), indicando dependencia. Se utilizó la prueba Chi-cuadrado con un nivel de significancia del 5%, validando previamente los supuestos requeridos. Las variables son categóricas e independientes, y el 100% de las casillas superan la frecuencia esperada de 5, cumpliendo la regla de Cochran sin valores menores a 1.

El estadístico de prueba Chi-cuadrado arrojó un valor de 50.2283 con 15 grados de libertad, resultando en un p-valor aproximado a 0.0000. Al ser el p-valor menor a 0.05, se rechaza la hipótesis nula, confirmando estadísticamente que la asistencia educativa depende del departamento. Sin embargo, la medida de tamaño de efecto V de Cramer resultó en 0.0359, lo que evidencia que, aunque existe dependencia estadística impulsada por el gran tamaño muestral, la intensidad real de esta asociación es nula o insignificante en la práctica.

Para profundizar en la distribución, se calcularon los intervalos de confianza al 95% para la proporción de asistencia en cada departamento mediante el método de Wald/Agresti-Coull. Las tasas de asistencia fluctúan mayormente entre el 28% y el 35%, destacándose el departamento 12 con la menor proporción estimada (23.76%) y los departamentos 1, 13 y 14 con tasas cercanas al 35%. Estos intervalos permiten visualizar diferencias locales, como el no solapamiento del departamento 12 con los de mayor asistencia, confirmando la heterogeneidad territorial.

En conclusión, los datos estadísticos confirman que el lugar de residencia tiene un impacto significativo en la asistencia al sistema educativo, rechazándose la independencia de las variables. No obstante, el bajo valor de la V de Cramer sugiere que el departamento es solo un factor secundario y que la asistencia debe estar fuertemente influenciada por otras variables no incluidas en este contraste, limitando su peso explicativo de forma aislada.

<u>Contraste 3:</u> Relación entre la edad y los años de estudio.

H_0: ρ=0: No existe una correlación estadísticamente significativa entre la edad de las personas y sus años de estudio.

H_1: ρ!=0: Existe una correlación estadísticamente significativa entre la edad de las personas y sus años de estudio.

Con nivel de significancia a=5%

Para evaluar la relación entre la edad y los años de estudio, se plantearon dos escenarios. La hipótesis nula H0: ρ=0 asume que no existe una correlación estadísticamente significativa entre las variables. La hipótesis alternativa H1: ρ!=0 sostiene que sí existe dicha correlación. Este contraste se evaluó considerando un nivel de significancia del 5%.

Primero se verificaron los supuestos requeridos para el análisis, confirmando que ambas variables son cuantitativas e independientes entre sí. Seguidamente se ejecutó la prueba de Shapiro-Wilk, obteniendo un p-valor de 0.0000 en ambas variables. Al comprobarse que los datos no siguen una distribución normal, se seleccionó la prueba no paramétrica de Spearman.

La prueba de correlación de Spearman arrojó un coeficiente ρ=0.1801 y un p-valor de 0.0000. Como el p-valor es estrictamente menor al nivel de significancia de 0.05, se rechaza la hipótesis nula de forma concluyente. Esto otorga la evidencia estadística suficiente para afirmar que efectivamente existe una relación significativa entre ambas variables analizadas.

En conclusión, la evidencia demuestra una relación válida en la cual se supone que a mayor edad, la persona tiene más años de estudio. Sin embargo, el coeficiente obtenido refleja que esta correlación positiva es débil o casi inexistente en la práctica, lo que implica que el progreso educativo depende fuertemente de otros factores.

<u>Contraste 4:</u> Nivel educativo y su relación con departamentos.
Hipótesis nula (H_0)

- Formal: El nivel educativo simplificado es independiente del departamento de residencia.
- Lenguaje natural: La distribución de personas según su nivel educativo es la misma en todos los departamentos.

Hipótesis alternativa (H_1)

- Formal: El nivel educativo simplificado depende del departamento de residencia.
- Lenguaje natural: La distribución de personas según su nivel educativo difiere entre al menos dos departamentos.

Nivel de significancia: $\alpha = 0.05$.

Ambas variables son categóricas nominales nivel_educ_simplificado con 6 categorías, NOMBRE_DPTO con 16 categorías.
La prueba adecuada para contrastar independencia entre dos variables categóricas es la Chi-cuadrado de independencia. Como medida de tamaño del efecto se usa la V de Cramér, que cuantifica la intensidad de la asociación en una escala de 0 a 1.

Por el mismo argumento expuesto en el contraste 1 se justifica la independencia entre individuos.
El supuesto de frecuencias esperadas se cumple. Las 15 casillas con frecuencias esperadas < 5 representan solo el 15.6% del total, muy por debajo del umbral del 20% que invalidará la prueba.

Se usó el estadístico $\chi^2 = 2122.2152$ con 75 grados de libertad y se obtuvo el valor de $p \approx 0 < 0{,}05$ y V de Cramer = 0.0905. Por tanto la decisión es: como $p < 0{,}05$, se rechaza H_0. Existe evidencia suficiente para afirmar que el nivel educativo depende del departamento de residencia.
Con V = 0.0905, la asociación es despreciable.

Conclusión del post hoc: Las desviaciones más fuertes se concentran en Asunción (residuo +26.07 en Terciaria) y Central (residuo −21.27 en Primaria), confirmando que estos dos departamentos concentran el mayor nivel educativo del país. En el extremo opuesto, Caazapá, Itapúa y San Pedro muestran los mayores excesos de nivel primario, y Canindeyú y Presidente Hayes los mayores defectos de nivel terciario.

En conclusion aunque la asociación es estadísticamente significativa, su magnitud global es despreciable (V = 0.09). Sin embargo, el análisis por celdas revela brechas sustantivas en categorías específicas: la proporción de personas con educación terciaria en Asunción (35.4%) más que duplica la de Caazapá (15.2%). La significancia extrema ($p < 0.05$) está fuertemente influida por el tamaño muestral (n = 51,861); con muestras más pequeñas, una asociación de esta magnitud podría no alcanzar significancia.

	Hipótesis	Prueba Aplicada	Supuestos verificados	Estadístico	Valor p	Intervalo de confianza	tamaño del efecto	Decisión
Contraste 1	H_0: $\mu_0 = \mu_1 = \ldots = \mu_{16}$ H_1 = al menos una μ_i es diferente.	Kruskal-Wallis, con post hoc de Dunn	Se verificó por medio de la prueba de Shapiro-Wilk la No normalidad de los datos de cada departamento, es visible en la tabla de arriba que Media != Mediana. Además realizando la prueba de Levene se verifica que las varianzas no son homogéneas (al menos una difiere). Ambas pruebas con un nivel de significancia α = 5%.	H = 1997	p ≈ 0			Se rechaza H_0
Contraste 2	H_o: Oij=Eij(i,j) H_1: Oij != Eij	Chi-cuadrado	. Ambas son variables categóricas . Son independientes entre sí . Supuesto de frecuencias esperadas: Total de casillas: 32 Casillas con esperados < 1: 0	x^2=50.2283	≈0.000	Anexo debajo de este cuadro.	0.0359	Se rechaza H_0

			Casillas con esperados < 5: 0 (0.0%) Porcentaje de casillas con esperados >= 5: 100.0% El supuesto de frecuencias esperadas SE CUMPLE.					
Contraste 3	H_0: ρ=0 H_1: ρ!=0	Spearman	. Ambas variables son cuantitativas. . Ambas variables son independientes entre sí. . Prueba de normalidad: Shapiro-Wilk (Edad): p-value = 0.0000 Shapiro-Wilk (Años de estudio): p-value = 0.0000	ρ=0.1801	≈0.000	…	0.1801	Se rechaza H_0
Contraste 4	H_0: O_i□ = E_i□ H_1:O_i□ ≠ E_i□	Chi-cuadrado de independencia + residuos ajustados con ajuste BH	• Ambas variables son categóricas • Observaciones independientes (diseño muestral EPHC 2025) • Frecuencias esperadas ≥ 1: 0 casillas (0%) • Frecuencias esperadas ≥ 5: 81 casillas de 96 (84.4%) El supuesto de frecuencias esperadas SE CUMPLE.	χ^2 = 2122.2152 (gl = 75)	p ≈ 0	IC 95% bootstrap de la proporción con nivel Terciaria/Universitaria: • Asunción: [33.90%, 36.88%] • Caazapá: [13.83%, 16.55%] (IC 95% Wilson: [33.93%, 36.88%] y [13.85%, 16.60%], respectivamente)	V de Cramér = 0.0905	Se rechaza H_0

Intervalos de confianza:

Contraste 2:

Intervalos de confianza(se aplicó el método de Wald/Agresti-coull)

	DPTO	total	Proporción (%)	IC 95% (%)
0	0	4035	29.91	[28.52% - 31.34%]
1	1	1819	34.85	[32.70% - 37.07%]
2	2	3206	32.13	[30.53% - 33.76%]
3	3	2718	29.84	[28.15% - 31.59%]
4	4	2235	28.72	[26.89% - 30.64%]
5	5	2971	33.39	[31.72% - 35.11%]
6	6	2610	31.65	[29.89% - 33.46%]

```
7      7   4252          31.96  [30.58% - 33.38%]
8      8   2480          32.18  [30.37% - 34.04%]
9      9   2006          29.36  [27.41% - 31.39%]
10    10   6113          32.95  [31.78% - 34.13%]
11    11   9153          31.14  [30.20% - 32.09%]
12    12   1637          23.76  [21.76% - 25.88%]
13    13   2242          35.28  [33.33% - 37.28%]
14    14   2532          34.20  [32.38% - 36.07%]
15    15   1852          32.61  [30.52% - 34.78%]
```

Comparación con bootstrap y clásico para robustez del contraste 2 sobre el departamento 12:

Para validar la robustez de las estimaciones del Contraste 2, se selecciono el Departamento doce para comparar su intervalo de confianza clásico con un intervalo estimado mediante la técnica de remuestreo Bootstrap. Este departamento específico cuenta con una muestra total de 1637 observaciones y presenta una proporción de asistencia educativa del 23,76%.

El intervalo de confianza clásico al 95% reportado inicialmente estimó un rango que va desde el 21,76% hasta el 25,88%. Por su parte, la estimación no paramétrica mediante el método Bootstrap, ejecutada con 10000 iteraciones de remuestreo con reemplazo, generó un intervalo de confianza que abarca desde el 21,69% hasta el 25,72%.

Al comparar los resultados de ambos métodos, se evidencia que los límites del intervalo generado por Bootstrap son prácticamente equivalentes a los calculados con el enfoque clásico. Esta coincidencia demuestra que el tamaño muestral es suficientemente grande, garantizando la fiabilidad y estabilidad de los intervalos reportados en la prueba de dependencia por departamento.

Link del repositorio en GitHub:
https://github.com/rodrigo-elias-01/Data-Science-Grupo15.git

Conclusiones de las Hipótesis e Implicancias para la Pregunta de Investigación

En el presente análisis exploratorio, se rechazaron las hipótesis nulas de los cuatro contrastes planteados, sosteniendo en todos los casos las hipótesis alternativas. Se comprobó estadísticamente que: 1) el nivel típico de años de estudio difiere entre departamentos; 2) la permanencia (asistencia educativa) depende del departamento de residencia; 3) existe una correlación positiva y significativa entre la edad y los años de estudio; y 4) la distribución del nivel educativo simplificado depende de la ubicación geográfica.

Para la pregunta de investigación central ("¿Existen diferencias significativas en el nivel educativo alcanzado y en la permanencia escolar entre los departamentos de Paraguay?"), los resultados implican una respuesta afirmativa. La evidencia confirma la existencia de una

heterogeneidad territorial, exponiendo brechas locales profundas, como la alta concentración de educación terciaria en Asunción y Central frente al exceso de nivel primario en Caazapá, San Pedro e Itapúa, o las caídas puntuales en las tasas de asistencia (ej. Departamento 12). No obstante, los tamaños del efecto calculado (V de Cramer y Coeficiente de Spearman) resultaron débiles o casi nulos. Esto implica que, aunque las diferencias geográficas y etarias son reales, el departamento de residencia y la edad actúan sólo como factores secundarios y no explican por sí solos el éxito o abandono dentro del sistema educativo.

Limitaciones de la Inferencia

Las inferencias obtenidas presentan limitaciones metodológicas que deben ser contextualizadas. La principal recae en el tamaño muestral excesivamente grande de la EPHC 2025 (n = 51.861 observaciones). Este volumen de datos hipersensibiliza las pruebas de contraste, provocando que diferencias minúsculas o irrelevantes en la práctica arrojen un nivel de significancia extremo ($p < 0.05$), lo cual explica la disonancia entre los p-valores concluyentes y los tamaños de efecto despreciables. Respecto a la representatividad y la dependencia temporal, si bien el diseño muestral probabilístico garantiza la validez transversal y la independencia de los individuos en el momento de la encuesta, los datos constituyen una "fotografía" estática del año 2025. Esta falta de seguimiento temporal (datos no longitudinales) impide determinar relaciones causales estrictas, medir el historial de abandono escolar dinámico o capturar el impacto que la migración interdepartamental tiene sobre la educación de las personas a lo largo del tiempo.

Variables para el Modelo Predictivo (Fase 3)

A partir de esta evidencia, las variables que se trasladarán al modelo predictivo de la Fase 3 incluyen el "Departamento de residencia", la "Edad", la "Asistencia actual" y el "Nivel educativo", “Años de estudio", “Porque no asiste o dejó de asistir”, “Título o diploma que obtuvo por el nivel más alto que alcanzó” y “la institución o programa de estudios al que asiste es del sector”.